

第4章 参数估计

吴密霞

北京工业大学统计与数据科学系

E-mail: wumixia@bjut.edu.cn



- 1 参数估计
- 2 分块LS估计
- 3 约束最小二乘估计
- 4 广义最小二乘估计
- 5 最小二乘统一理论*
- 6 最小二乘估计的稳健性
- 7 两步估计
- 8 协方差改进估计

教材

- 吴密霞, 王松桂. 2024. 线性模型引论 (第2版), 科学出版社.



线性模型

- 考虑线性模型：

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad (4.1)$$

这里 \mathbf{y} 为 $n \times 1$ 观测向量, \mathbf{X} 为 $n \times p$ 的设计矩阵, $\boldsymbol{\beta}$ 为 $p \times 1$ 未知参数向量, \mathbf{e} 为随机误差, 且满足 **Gauss-Markov假设**:

$$E(\mathbf{e}) = \mathbf{0}, \quad \text{Cov}(\mathbf{e}) = \sigma^2 \mathbf{I}_n,$$

其中 σ^2 为误差方差, $\sigma^2 > 0$. 称模型为Gauss-Markov模型.

- 当 $\text{rk}(\mathbf{X}) = r \leq p$ 时, 称其为降秩线性模型
- 当 $\text{rk}(\mathbf{X}) = p$ 时, 称其为满秩线性模型

最小二乘估计

最小二乘法的思想

β 的真值应该使误差向量 $e = y - X\beta$ 的长度平方

$$Q(\beta) = \|e\|^2 = \|y - X\beta\|^2 = (y - X\beta)'(y - X\beta)$$

达到最小.

应该通过极小化 $Q(\beta)$ 来求 β 的估计. 注意到

$$Q(\beta) = y'y - 2y'X\beta + \beta'X'X\beta,$$

利用矩阵微商公式(见第二章)

$$\frac{\partial y'X\beta}{\partial \beta} = X'y, \quad \frac{\partial \beta'X'X\beta}{\partial \beta} = 2X'X\beta,$$

最小二乘估计

于是

$$\frac{\partial Q(\beta)}{\partial \beta} = -2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\beta.$$

令其等于0, 得到正则方程

$$\mathbf{X}'\mathbf{X}\beta = \mathbf{X}'\mathbf{y}. \quad (4.2)$$

因为 $\mathbf{X}'\mathbf{y} \in \mathcal{M}(\mathbf{X}') = \mathcal{M}(\mathbf{X}'\mathbf{X})$, 于是正则方程(4.2) 是相容的.

根据定理2.3.3, 正则方程(4.2)的解为

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'\mathbf{y},$$

这里 $(\mathbf{X}'\mathbf{X})^{-}$ 是 $\mathbf{X}'\mathbf{X}$ 的任意一个广义逆.

最小二乘估计

- 根据函数极值理论知: $\hat{\beta}$ 只是函数 $Q(\beta)$ 的驻点. 下证 $\hat{\beta}$ 使 $Q(\beta)$ 达到最小. 事实上, 对任意一个 β , 都有

$$\begin{aligned} Q(\beta) &= \|\mathbf{y} - \mathbf{X}\beta\|^2 \\ &= \|\mathbf{y} - \mathbf{X}\hat{\beta} + \mathbf{X}(\hat{\beta} - \beta)\|^2 \\ &= \|\mathbf{y} - \mathbf{X}\hat{\beta}\|^2 + (\hat{\beta} - \beta)' \mathbf{X}' \mathbf{X} (\hat{\beta} - \beta) \end{aligned}$$

由于第二项总是非负的, 于是

$$Q(\beta) \geq \|\mathbf{y} - \mathbf{X}\hat{\beta}\|^2 = Q(\hat{\beta}).$$

此式表明, $\hat{\beta}$ 确使 $Q(\beta)$ 达到最小.

最小二乘估计

- 现证使 $Q(\beta)$ 达到最小的必是 $\hat{\beta}$. 事实上,

$$Q(\beta) \geq \|\mathbf{y} - \mathbf{X}\hat{\beta}\|^2 = Q(\hat{\beta})$$

等号成立, 当且仅当

$$(\hat{\beta} - \beta)' \mathbf{X}' \mathbf{X} (\hat{\beta} - \beta) = \mathbf{0},$$

等价地

$$\mathbf{X}(\hat{\beta} - \beta) = \mathbf{0}.$$

不难证明, 上式又等价于

$$\mathbf{X}' \mathbf{X} \beta = \mathbf{X}' \mathbf{X} \hat{\beta} = \mathbf{X}' \mathbf{y},$$

这就证明了, 使 $Q(\beta)$ 达到最小值的点必为正则方程的解

$$\hat{\beta} = (\mathbf{X}' \mathbf{X})^{-} \mathbf{X}' \mathbf{y}.$$

最小二乘估计

- 若 $\text{rk}(\mathbf{X}) = p$, 则 $\mathbf{X}'\mathbf{X}$ 可逆, β 可估,

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

是 β 的无偏估计, 称其为 β 的最小二乘(least squares, LS)估计.

- 若 $\text{rk}(\mathbf{X}) < p$, 则 $\hat{\boldsymbol{\beta}}$ 不再是 β 的无偏估计,

$$E(\hat{\boldsymbol{\beta}}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\boldsymbol{\beta} \neq \boldsymbol{\beta}.$$

此时 β 的线性无偏估计根本不存在, 故称 β 不可估.

反证法. 若存在 $p \times n$ 矩阵 \mathbf{A} , 使得对一切 β 成立, 都有 $E(\mathbf{A}\mathbf{y}) = \mathbf{A}\mathbf{X}\boldsymbol{\beta} = \boldsymbol{\beta} \iff \mathbf{A}\mathbf{X} = \mathbf{I}_p$, 这就与 $\text{rk}(\mathbf{A}\mathbf{X}) \leq \text{rk}(\mathbf{X}) < p = \text{rk}(\mathbf{I}_p)$ 相矛盾.

可估函数

若 $\text{rk}(\mathbf{X}) < p$, 则 β 不可估. 此时可考虑 β 的线性组合 $c'\beta$.

定义4.1.1

若存在 $n \times 1$ 向量 a , 使得

$$E(a'y) = c'\beta$$

对一切 β 成立, 则称 $c'\beta$ 是可估函数 (estimable function).

定理4.1.1

$c'\beta$ 是可估函数 $\iff c \in \mathcal{M}(\mathbf{X}')$.

证明 $c'\beta$ 是可估函数 \iff 存在 $a_{n \times 1}$, 使得对一切 β 都有 $E(a'y) = c'\beta$

$$\iff a' \mathbf{X} \beta = c'\beta, \text{ 对一切 } \beta \iff c = \mathbf{X}'a.$$

最小二乘估计

定理4.1.1表明：

- 使 $c'\beta$ 可估的全体 $p \times 1$ 向量 c 构成子空间 $\mathcal{M}(\mathbf{X}')$ ；
- 若 $c'_1\beta$ 和 $c'_2\beta$ 均可估，则任意线性组合 $\alpha_1c'_1\beta + \alpha_2c'_2\beta$ 也可估。
- 若 c_1 和 c_2 为线性无关，则称可估函数 $c'_1\beta$ 和 $c'_2\beta$ 是线性无关的。
- 线性无关的可估函数组最多含有 $\text{rk}(\mathbf{X}) = r$ 个可估函数。
- 对于任一可估函数 $c'\beta$, $c'\hat{\beta}$ 与 $(\mathbf{X}'\mathbf{X})^{-}$ 的选择无关，**是唯一的**，

$$c'\hat{\beta} = c'(\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'y = a'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'y = a'\mathbf{X}(\mathbf{X}'\mathbf{X})^{+}\mathbf{X}'y$$

- $c'\hat{\beta}$ 为 $c'\beta$ 的无偏估计, $E(c'\hat{\beta}) = a'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'\mathbf{X}\beta = a'\mathbf{X}\beta = c'\beta$.

最小二乘估计

定义4.1.2

对可估函数 $c'\beta$, 称 $\hat{c}'\hat{\beta}$ 为 $c'\beta$ 的 LS 估计.

- 记 $\mathbf{C} = (c_1, \dots, c_m)'$ 是一个 $m \times p$ 的常数矩阵. 若 $c_1'\beta, \dots, c_m'\beta$ 皆可估, 则称 $\mathbf{C}\beta$ 可估. 易证

$$\mathbf{C}\beta \text{ 可估} \iff \mathcal{M}(\mathbf{C}') \subseteq \mathcal{M}(\mathbf{X}').$$

- 若 $\mathbf{C}\beta$ 可估, 则 $\mathbf{C}\beta$ 的 LS 估计为 $\mathbf{C}\hat{\beta}$.

记 $\mathbf{X} = (x_1, \dots, x_n)', \quad \boldsymbol{\mu} = (\mu_1, \dots, \mu_n)' = \mathbf{X}\beta$.

最小二乘估计

Guass-Markov模型的分量形式:

$$y_i = \mathbf{x}'_i \boldsymbol{\beta} + e_i, \quad i = 1, \dots, n,$$

其中, \mathbf{x}_i 为 \mathbf{X} 的第*i*行向量, e_i 为误差向量的第*i*个分量,

$$E(e_i) = 0, \quad \text{Cov}(e_i) = \sigma^2, \quad \text{Cov}(e_i, e_j) = 0, (i \neq j).$$

- $\mu_i = \mathbf{x}'_i \boldsymbol{\beta}, i = 1, \dots, n$ 是*n*个可估函数;
- 任意可估函数都是 $\mu = \mathbf{X}\boldsymbol{\beta}$ 的线性函数, 即 $\mathbf{c}'\boldsymbol{\beta} = \mathbf{a}'\mu$
- μ 的LS估计为 $\hat{\mu} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{P}_{\mathbf{X}}\mathbf{y}$.

σ^2 的LS估计

- 残差向量

$$\hat{\boldsymbol{e}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}} = (\mathbf{I}_n - \mathbf{P}_{\mathbf{X}})\mathbf{y},$$

作为误差向量的一个“估计”，它对研究关于误差假设的合理性起重要作用。易证： $E(\hat{\boldsymbol{e}}) = \mathbf{0}$ ， $\text{Cov}(\hat{\boldsymbol{e}}) = \sigma^2(\mathbf{I}_n - \mathbf{P}_{\mathbf{X}})$ 。

- 基于 $\hat{\boldsymbol{e}}$ 可构造 σ^2 的估计

$$\hat{\sigma}^2 = \frac{\hat{\boldsymbol{e}}' \hat{\boldsymbol{e}}}{n-r} = \frac{\|\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|^2}{n-r},$$

这里 $r = \text{rk}(\mathbf{X})$ 。通常称 $\hat{\sigma}^2$ 为 σ^2 的 LS 估计。

σ^2 的LS 估计

定理4.1.3

$\hat{\sigma}^2$ 是 σ^2 的无偏估计.

证明 因 $\mathbf{I}_n - \mathbf{P}_X$ 为幂等阵, 于是

$$\hat{\mathbf{e}}'\hat{\mathbf{e}} = \mathbf{y}'(\mathbf{I}_n - \mathbf{P}_X)\mathbf{y},$$

利用定理3.2.1和等式 $(\mathbf{I}_n - \mathbf{P}_X)\mathbf{X} = \mathbf{0}$, 可证得

$$E(\hat{\mathbf{e}}'\hat{\mathbf{e}}) = (\mathbf{X}\boldsymbol{\beta})'(\mathbf{I}_n - \mathbf{P}_X)\mathbf{X}\boldsymbol{\beta} + \text{tr}(\mathbf{I}_n - \mathbf{P}_X)\text{Cov}(\mathbf{y}) = \sigma^2 \text{tr}(\mathbf{I}_n - \mathbf{P}_X),$$

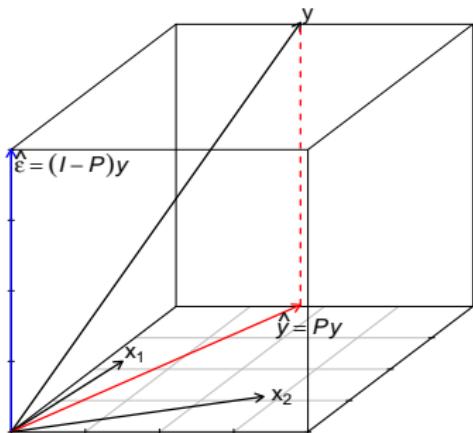
再利用迹和幂等阵的性质, 得

$$E(\hat{\mathbf{e}}'\hat{\mathbf{e}}) = \sigma^2[n - \text{tr}(\mathbf{P}_X)] = \sigma^2[n - \text{rk}(\mathbf{X})].$$

定理得证.

LS估计和残差的几何性质

LS估计 $\hat{\beta}$ 和残差向量 \hat{e} 分别为 y 向 $\mathcal{M}(\mathbf{X}')$ 和 $\mathcal{M}(\mathbf{X}')$ 的正交补空间上的正交投影, 如图所示:



注意

- 残差平方和 $\text{SS}_e = \hat{\mathbf{e}}' \hat{\mathbf{e}}$ 可被表达为

$$\text{SS}_e = \|\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|^2 = \mathbf{y}'(\mathbf{I}_n - \mathbf{P}_{\mathbf{X}})\mathbf{y} = \mathbf{e}'(\mathbf{I}_n - \mathbf{P}_{\mathbf{X}})\mathbf{e}$$

- 对任一可估函数 $\mathbf{c}'\boldsymbol{\beta}$ 的 LS 估计 唯一, 因为

$$\mathbf{c}'\hat{\boldsymbol{\beta}} = \mathbf{a}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{a}'\mathbf{P}_{\mathbf{X}}\mathbf{y} = \mathbf{a}'\mathbf{X}(\mathbf{X}'\mathbf{X})^+\mathbf{X}'\mathbf{y}$$

- 可估函数 $\mathbf{c}'\boldsymbol{\beta}$ 的线性无偏估计有无穷多个.

事实上, 如果 $\mathbf{a}'\mathbf{y}$ 为 $\mathbf{c}'\boldsymbol{\beta}$ 的一个无偏估计, $\mathbf{b}'\mathbf{X} = 0$, 则

$$E(\mathbf{a} + \mathbf{b})'\mathbf{y} = E(\mathbf{a}'\mathbf{y}) + E(\mathbf{b}'\mathbf{y}) = \mathbf{c}'\boldsymbol{\beta} + \mathbf{b}'\mathbf{X}'\boldsymbol{\beta} = \mathbf{c}'\boldsymbol{\beta}$$

LS估计的最优性质

Gauss-Markov定理

对任意的可估函数 $c'\beta$, LS估计 $c'\hat{\beta}$ 为惟一的最佳线性无偏(best linear unbiased, BLU)估计, 即在其线性无偏估计当中, $c'\hat{\beta}$ 的方差最小.

证明 显然 $c'\hat{\beta}$ 为 $c'\beta$ 的线性无偏估计. 现证 $c'\hat{\beta}$ 的方差最小.

$$\text{Var}(c'\hat{\beta}) = \text{Var}(c'(\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'\mathbf{y}) = \sigma^2 c'(\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-}c.$$

由 $c'\beta$ 的可估性, 知存在向量 $\alpha_{n \times 1}$, 使得 $c = \mathbf{X}'\alpha$, 于是,

$$\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-}c = \mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'\alpha = \mathbf{X}'\alpha = c,$$

从而得 $\text{Var}(c'\hat{\beta}) = \sigma^2 c'(\mathbf{X}'\mathbf{X})^{-}c$.

Gauss-Markov定理证明

另一方面, 设 $\mathbf{a}'\mathbf{y}$ 为 $\boldsymbol{\beta}$ 的任一无偏估计, 于是有 $\mathbf{X}'\mathbf{a} = \mathbf{c}$. 从而

$$\begin{aligned}\text{Var}(\mathbf{a}'\mathbf{y}) - \text{Var}(\mathbf{c}'\hat{\boldsymbol{\beta}}) &= \sigma^2[\mathbf{a}'\mathbf{a} - \mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{c}] \\ &= \sigma^2(\mathbf{a}' - \mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')(\mathbf{a} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{c}) \\ &= \sigma^2\|\mathbf{a} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{c}\|^2 \geq 0,\end{aligned}$$

并且等号成立 $\iff \mathbf{a}' = \mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \iff \mathbf{a}'\mathbf{y} = \mathbf{c}'\hat{\boldsymbol{\beta}}$. 定理证毕.

这个定理奠定了LS估计在线性模型参数估计理论中的地位.

注 它所刻画的LS估计在线性无偏估计类中的最优性. 但在另一个度量估计优劣的标准 (如MSE), 它可能并不一定最优

LS估计的最优性质

推论4.1.1

设 $\psi_i = \mathbf{c}'_i \boldsymbol{\beta}$, $i = 1, \dots, k$ 都是可估函数, $\alpha_i, i = 1, \dots, k$ 是实数, 则 $\psi = \sum_{i=1}^k \alpha_i \psi_i$ 也可估, 且 $\hat{\psi} = \sum_{i=1}^k \alpha_i \hat{\psi}_i = \sum_{i=1}^k \alpha_i \mathbf{c}'_i \hat{\boldsymbol{\beta}}$ 是 ψ 的BLU估计.

推论4.1.2

设 $\mathbf{c}'\boldsymbol{\beta}$ 和 $\mathbf{d}'\boldsymbol{\beta}$ 是两个可估函数, 则

$$\text{Var}(\mathbf{c}'\hat{\boldsymbol{\beta}}) = \sigma^2 \mathbf{c}' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{c},$$

$$\text{Cov}(\mathbf{c}'\hat{\boldsymbol{\beta}}, \mathbf{d}'\hat{\boldsymbol{\beta}}) = \sigma^2 \mathbf{c}' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{d},$$

并且上述两式与所含广义逆的选择无关.

LS估计的最优性质

对于可估函数 $\mathbf{C}\beta$, 其线性无偏估计类可表示为

$$\mathcal{D} = \{\mathbf{Ay}; \mathbf{A} \text{满足条件 } \mathbf{AX} = \mathbf{C}\}.$$

注意到 $\text{Cov}(\mathbf{Ay}) = \sigma^2 \mathbf{AA}'$, $\text{cov}(\mathbf{C}\hat{\beta}) = \sigma^2 \mathbf{C}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{C}'$,

$$\text{cov}(\mathbf{Ay}) - \text{cov}(\mathbf{C}\hat{\beta}) = \sigma^2 \mathbf{A} (\mathbf{I}_p - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}') \mathbf{A}' \geq \mathbf{0}. \text{ (半正定)}$$

定理4.1.4

对于可估函数 $\mathbf{C}\beta$, LS估计 $\mathbf{C}\hat{\beta}$ 为其唯一的最小协方差阵线性无偏
(minimum dispersion linear unbiased, MDLU) 估计.

- 若 \mathbf{Ay} 为可估函数 $\mathbf{C}\beta$ 的MDLU估计, 则其分量也是MVLU的.

LS估计的最优性质

定理4.1.5

对正态线性模型

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n),$$

设 $\mathbf{c}'\boldsymbol{\beta}$ 为任一可估函数, 则

(1) LS估计 $\mathbf{c}'\hat{\boldsymbol{\beta}}$ 是 $\mathbf{c}'\boldsymbol{\beta}$ 的极大似然(maximum likelihood, ML)估计, 且

$$\mathbf{c}'\hat{\boldsymbol{\beta}} \sim N(\mathbf{c}'\boldsymbol{\beta}, \sigma^2 \mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{c});$$

(2) $(n - r)\hat{\sigma}^2/n$ 为 σ^2 的ML估计, 且 $(n - r)\hat{\sigma}^2/\sigma^2 \sim \chi_{n-r}^2$;

(3) $\mathbf{c}'\hat{\boldsymbol{\beta}}$ 与 $\hat{\sigma}^2$ 相互独立, 这里 $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$, $r = \text{rk}(\mathbf{X})$.

定理4.1.5的证明

证明 (1) 记 $\mu = \mathbf{X}\beta$, 考虑 μ 和 σ^2 的似然函数

$$L(\mu, \sigma^2) = \frac{1}{(2\pi)^{\frac{n}{2}} \sigma^n} \exp \left\{ -\frac{1}{2\sigma^2} \|\mathbf{y} - \mu\|^2 \right\},$$

取对数, 略去常数项, 得

$$\log L(\mu, \sigma^2) = -\frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \|\mathbf{y} - \mu\|^2.$$

对均值向量 μ 的 LS 估计 $\hat{\mu} = \mathbf{X}\hat{\beta}$, 我们有

$$\|\mathbf{y} - \hat{\mu}\|^2 = \|\mathbf{y} - \mathbf{X}\hat{\beta}\|^2 = \min \|\mathbf{y} - \mathbf{X}\beta\|^2 = \min_{\mu=\mathbf{X}\beta} \|\mathbf{y} - \mu\|^2.$$

于是, 对每一个固定的 σ^2 ,

$$\log L(\hat{\mu}, \sigma^2) \geq \log L(\mu, \sigma^2),$$

定理4.1.5的证明

而

$$\log L(\hat{\mu}, \sigma^2) = -\frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \|\mathbf{y} - \hat{\mu}\|^2,$$

在 $\tilde{\sigma}^2 = \frac{1}{n} \|\mathbf{y} - \hat{\mu}\|^2$ 达到最大. 于是

$$\hat{\mu} = \mathbf{X}\hat{\beta}, \quad \tilde{\sigma}^2 = \frac{1}{n} \|\mathbf{y} - \hat{\mu}\|^2$$

分别为 μ 和 σ^2 的ML估计.

对任一可估函数 $\mathbf{c}'\beta$, 存在 $\alpha \in R^n$, 使得 $\mathbf{c}'\beta = \alpha'\mathbf{X}\beta = \alpha'\mu$,
由ML估计的不变性, $\mathbf{c}'\beta$ 的ML估计为

$$\alpha'\hat{\mu} = \alpha'\mathbf{X}\hat{\beta} = \mathbf{c}'\hat{\beta}.$$

定理4.1.5的证明

又因 $\mathbf{c}'\hat{\boldsymbol{\beta}}$ 为 y 的线性函数, 而 $y \sim N_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I}_n)$, 依定理3.3.4知,

$$\mathbf{c}'\hat{\boldsymbol{\beta}} \sim N(\mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{c}).$$

由 $\mathbf{c}'\boldsymbol{\beta}$ 可估, 得 $\mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X} = \mathbf{c}'$, (1)得证.

(2) 的第一条结论已证. 因为 $\mathbf{P}_X\mathbf{X} = \mathbf{X}$, 所以

$$\frac{(n-r)\hat{\sigma}^2}{\sigma^2} = \frac{\hat{\mathbf{e}}'\hat{\mathbf{e}}}{\sigma^2} = \frac{\mathbf{y}'(\mathbf{I}_n - \mathbf{P}_X)\mathbf{y}}{\sigma^2} = \frac{\mathbf{e}'(\mathbf{I}_n - \mathbf{P}_X)\mathbf{e}}{\sigma^2} = \mathbf{z}'(\mathbf{I}_n - \mathbf{P}_X)\mathbf{z},$$

其中 $\mathbf{z} = \mathbf{e}/\sigma \sim N_n(\mathbf{0}, \mathbf{I}_n)$. 由 $\mathbf{I}_n - \mathbf{P}_X$ 的幂等性及

$$\text{rk}(\mathbf{I}_n - \mathbf{P}_X) = \text{tr}(\mathbf{I}_n - \mathbf{P}_X) = n - \text{tr}(\mathbf{P}_X) = n - \text{rk}(\mathbf{X}) = n - r,$$

利用定理3.4.3, 即得 $(n-r)\hat{\sigma}^2/\sigma^2 \sim \chi_{n-r}^2$.

定理4.1.5的证明

(3) 注意到 $c'\hat{\beta}$ 与 $\hat{\sigma}^2$ 分别为正态向量 y 的线性型和二次型, 和

$$c'(\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'(\mathbf{I}_n - \mathbf{P}_{\mathbf{X}}) = \mathbf{0},$$

由正态向量的线性型和二次型独立性定理3.5.1 推得(3).

LS估计的最优性质

定理4.1.6

对于正态线性模型 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$, $\mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$,

- (1) $T_1 = \mathbf{y}'\mathbf{y}$ 和 $T_2 = \mathbf{X}'\mathbf{y}$ 为完全充分统计量,
- (2) 对任一可估函数 $\mathbf{c}'\boldsymbol{\beta}$, $\mathbf{c}'\hat{\boldsymbol{\beta}}$ 为其惟一的最小方差无偏(minimum variance unbiased, MVU)估计, $\hat{\sigma}^2$ 为 σ^2 的惟一MVU估计.

证明 观测向量 \mathbf{y} 的概率密度函数为

$$\begin{aligned} f(\mathbf{y}) &= \frac{1}{(2\pi)^{\frac{n}{2}} \sigma^n} \exp \left\{ -\frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})' (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) \right\} \\ &= \frac{1}{(2\pi)^{\frac{n}{2}} \sigma^n} \exp \left\{ -\frac{1}{2\sigma^2} \mathbf{y}'\mathbf{y} + \frac{1}{\sigma^2} \mathbf{y}'\mathbf{X}\boldsymbol{\beta} - \frac{1}{2\sigma^2} \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta} \right\}, \end{aligned}$$

LS估计的最优性质

记 $\theta_1 = -\frac{1}{2\sigma^2}$, $\theta_2 = \frac{\beta}{\sigma^2}$, 它们是所谓的自然参数, 则上式可改写为

$$f(\mathbf{y}) = \frac{1}{(-\pi)^{\frac{n}{2}}} \theta_1^n \exp \left\{ \frac{1}{4\theta_1} \boldsymbol{\theta}'_2 \mathbf{X}' \mathbf{X} \boldsymbol{\theta}_2 \right\} \exp\{\theta_1 T_1 + \boldsymbol{\theta}_2 \mathbf{T}_2\}.$$

将 $f(\mathbf{y})$ 表成了指数族的自然形式, 其参数空间为

$$\Theta = \left\{ \begin{pmatrix} \theta_1 \\ \boldsymbol{\theta}_2 \end{pmatrix}; \quad \theta_1 < 0, \quad \boldsymbol{\theta}_2 \in R^p \right\}.$$

依定理2.2 (陈希孺, 1999)知:

$T_1 = \mathbf{y}' \mathbf{y}$ 和 $\mathbf{T}_2 = \mathbf{X}' \mathbf{y}$ 为完全充分统计量.

LS估计的最优性质

对任一可估函数 $\mathbf{c}'\boldsymbol{\beta}$,其LS估计

$$\mathbf{c}'\hat{\boldsymbol{\beta}} = \mathbf{c}'(\mathbf{X}'\mathbf{X})^{-}\mathbf{T}_2,$$

误差方差 σ^2 的LS估计

$$\hat{\sigma}^2 = (\mathbf{T}_1 - \mathbf{T}_2(\mathbf{X}'\mathbf{X})^{-}\mathbf{T}_2)/(n - r),$$

它们都是完全充分统计量的函数. 同时我们知道, 它们都是无偏估计, 依Lehmann-Scheffe定理立得 $\mathbf{c}'\hat{\boldsymbol{\beta}}$ 和 $\hat{\sigma}^2$ 分别是 $\mathbf{c}'\boldsymbol{\beta}$ 和 σ^2 的惟一MVU估计. 定理证毕.

LS估计的性质

线性模型 $y = \mathbf{X}\beta + e$ 下, 可估函数 $c'\beta$ 的 LS 估计 $c'\hat{\beta}$ 的性质

- MVU性:

若 $e \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ (正态线性模型), 则任一可估函数 $c'\beta$ 的 LS 估计 $c'\hat{\beta}$ 在其所有的(线性的和非线性)无偏估计类中方差最小.

- BLU性:

若 $E(e) = \mathbf{0}$, $\text{cov}(e) = \sigma^2 \mathbf{I}_n$ (Guass-Markov模型下), 则可估函数 $c'\beta$ 的 LS 估计 $c'\hat{\beta}$ 在线性无偏估计类中方差最小性.

LS估计的最优性质

定理4.1.7

对于正态线性模型 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{e}$, $\boldsymbol{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$, 其任意可估函数 $\mathbf{C}\boldsymbol{\beta}$ 的 ML 估计 $\mathbf{C}\hat{\boldsymbol{\beta}}$ 为其实无偏估计类中协方差阵最小 (minimum dispersion unbiased, MDU) 估计. 当 $\text{rk}(\mathbf{X}) = p$ 时, $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ 的协方差阵正好等于 Cramér-Rao 下界

$$-\left[\frac{\partial^2 \ln L(\boldsymbol{\mu}, \sigma^2)}{\partial^2 \boldsymbol{\beta}}\right]^{-1} = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1},$$

这里 $\boldsymbol{\mu} = \mathbf{X}\boldsymbol{\beta}$.

例子 设 μ 为一物体的重量, 现对该物体测量 n 次, 其测量值记为 y_1, \dots, y_n . 若 $y_i \sim N(\mu, \sigma^2)$, 则 $\bar{y} = \sum y_i/n$ 为 μ MDU 估计.

线性模型的分块运算主要应用于以下两种情形：

- 对参数分块

当模型往往包含冗余参数（nuisance parameter）时，感兴趣参数的LS估计的降秩表达

- 对样本分块

Meta分析或大规模数据中，由于隐私保护或计算机存储运算能力的限制，多地存储的子数据集不能被传输到一台中央机器来分析，需要分块运算。

参数分块的LS估计

对线性模型 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{e}$ 参数分块

$$\mathbf{y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \boldsymbol{e}, \quad \mathbb{E}(\boldsymbol{e}) = \mathbf{0}, \quad \text{cov}(\boldsymbol{e}) = \sigma^2 \mathbf{I}_n.$$

$\boldsymbol{\beta} = (\boldsymbol{\beta}'_1, \boldsymbol{\beta}'_2)'$ 的LS解

$$\begin{pmatrix} \hat{\boldsymbol{\beta}}_1 \\ \hat{\boldsymbol{\beta}}_2 \end{pmatrix} = \begin{pmatrix} \mathbf{X}'_1 \mathbf{X}_1 & \mathbf{X}'_1 \mathbf{X}_2 \\ \mathbf{X}'_2 \mathbf{X}_1 & \mathbf{X}'_2 \mathbf{X}_2 \end{pmatrix}^{-1} \begin{pmatrix} \mathbf{X}'_1 \mathbf{y} \\ \mathbf{X}'_2 \mathbf{y} \end{pmatrix}.$$

- 当 $\text{rk}(\mathbf{X}) = p$ 时, $\boldsymbol{\beta}_1$ 和 $\boldsymbol{\beta}_2$ 皆可估, 其LS估计为

$$\hat{\boldsymbol{\beta}}_2 = (\mathbf{X}'_2 \mathbf{N}_{\mathbf{X}_1} \mathbf{X}_2)^{-1} \mathbf{X}'_2 \mathbf{N}_{\mathbf{X}_1} \mathbf{y}, \quad \hat{\boldsymbol{\beta}}_1 = (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{X}'_1 (\mathbf{y} - \mathbf{X}_2 \hat{\boldsymbol{\beta}}_2),$$

这里 $\mathbf{N}_{\mathbf{X}_1} = \mathbf{I}_n - \mathbf{X}_1 (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{X}'_1$.

参数分块的LS估计

- 假定 \mathbf{X}_2 是列满秩, 并且 \mathbf{X}_1 的列与 \mathbf{X}_2 的列线性无关, 即

$$\mathcal{M}(\mathbf{X}_1) \cap \mathcal{M}(\mathbf{X}_2) = \{\mathbf{0}\}, \quad \text{rk}(\mathbf{X}_2) = p_2.$$

定理4.2.2

$$\hat{\boldsymbol{\beta}}_2 = (\mathbf{X}'_2 \mathbf{N}_{\mathbf{X}_1} \mathbf{X}_2)^{-1} \mathbf{X}'_2 \mathbf{N}_{\mathbf{X}_1} \mathbf{y}, \quad \text{cov}(\hat{\boldsymbol{\beta}}_2) = \sigma^2 (\mathbf{X}'_2 \mathbf{N}_{\mathbf{X}_1} \mathbf{X}_2)^{-1}$$

$$\hat{\boldsymbol{\beta}}_1 = (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{X}'_1 (\mathbf{y} - \mathbf{X}_2 \hat{\boldsymbol{\beta}}_2)$$

对任一可估函数 $\mathbf{c}' \boldsymbol{\beta}_1$, $\text{var}(\mathbf{c}' \hat{\boldsymbol{\beta}}_1) = \sigma^2 \mathbf{c}' \mathbf{M} \mathbf{c}$, 这里,

$$\mathbf{M} = (\mathbf{X}'_1 \mathbf{X}_1)^{-1} + (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{X}'_1 \mathbf{X}_2 (\mathbf{X}'_2 \mathbf{N}_{\mathbf{X}_1} \mathbf{X}_2)^{-1} \mathbf{X}_2 \mathbf{X}'_1 (\mathbf{X}'_1 \mathbf{X}_1)^{-1}.$$

参数分块的LS估计的直观解释

- $\hat{\beta}_2 = (\mathbf{X}'_2 \mathbf{N}_{\mathbf{X}_1} \mathbf{X}_2)^{-1} \mathbf{X}'_2 \mathbf{N}_{\mathbf{X}_1} \mathbf{y}$ 为约简模型

$$\mathbf{N}_{\mathbf{X}_1} \mathbf{y} = \mathbf{N}_{\mathbf{X}_1} \mathbf{X}_2 \beta_2 + \varepsilon \quad (4.3)$$

的LS估计, 其中 $\varepsilon = \mathbf{N}_{\mathbf{X}_1} e$.

- $\hat{\beta}_1 = (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{X}'_1 (\mathbf{y} - \mathbf{X}_2 \hat{\beta}_2)$ 为将 $\hat{\beta}_2$ 替换原模型 $\mathbf{y} = \mathbf{X}_1 \beta_1 + \mathbf{X}_2 \beta_2 + e$ 的 β_2 后所得模型

$$\tilde{\mathbf{y}} = \mathbf{X}_1 \beta_1 + e \quad (4.4)$$

的LS解, 其中 $\tilde{\mathbf{y}} = \mathbf{y} - \mathbf{X}_2 \hat{\beta}_2$.

参数分块的LS估计

如果 $\mathbf{X}'_1 \mathbf{X}_2 = \mathbf{0}$, 则

$$\mathbf{N}_{\mathbf{X}_1} \mathbf{X}_2 = (\mathbf{I}_n - \mathbf{P}_{\mathbf{X}_1}) \mathbf{X}_2 = \mathbf{X}_2.$$

推论4.2.1

假设模型 $\mathbf{y} = \mathbf{X}_1 \boldsymbol{\beta}_1 + \mathbf{X}_2 \boldsymbol{\beta}_2 + \mathbf{e}$ 满足 $\mathbf{X}'_1 \mathbf{X}_2 = \mathbf{0}$, $\text{rk}(\mathbf{X}_2) = p_2$, 则可估函数 $\mathbf{c}' \boldsymbol{\beta}_1$ 和 $\boldsymbol{\beta}_2$ 的 LS 估计为

$$\mathbf{c}' \hat{\boldsymbol{\beta}}_1 = \mathbf{c}' (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{X}'_1 \mathbf{y}, \quad \hat{\boldsymbol{\beta}}_2 = (\mathbf{X}'_2 \mathbf{X}_2)^{-1} \mathbf{X}'_2 \mathbf{y},$$

$$\text{且 } \text{var}(\mathbf{c}' \hat{\boldsymbol{\beta}}_1) = \sigma^2 \mathbf{c}' (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{c}', \quad \text{cov}(\hat{\boldsymbol{\beta}}_2) = \sigma^2 (\mathbf{X}'_2 \mathbf{X}_2)^{-1}.$$

参数分块的LS估计

对于多分块模型：

$$\mathbf{y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \cdots + \mathbf{X}_k\boldsymbol{\beta}_k + \boldsymbol{e}, \quad E(\boldsymbol{e}) = \mathbf{0}, \quad \text{cov}(\boldsymbol{e}) = \sigma^2 \mathbf{I}_n,$$

当 \mathbf{X}_i 列满秩，且 $\mathbf{X}'_i \mathbf{X}_j = \mathbf{0}$, ($i \neq j$) 时, $(\boldsymbol{\beta}'_1, \dots, \boldsymbol{\beta}'_k)'$ 的LS估计为

$$\begin{pmatrix} \hat{\boldsymbol{\beta}}_1 \\ \vdots \\ \hat{\boldsymbol{\beta}}_k \end{pmatrix} = \begin{pmatrix} (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{X}'_1 \mathbf{y} \\ \vdots \\ (\mathbf{X}'_k \mathbf{X}_k)^{-1} \mathbf{X}'_k \mathbf{y} \end{pmatrix}$$

此时 $\boldsymbol{\beta}_i$ 的LS估计等价于子模型

$$\mathbf{y} = \mathbf{X}_i \boldsymbol{\beta}_i + \boldsymbol{e}$$

的的LS估计.

参数分块的LS估计

例4.2.1 考虑线性回归模型

$$\mathbf{y} = \mathbf{1}_n\beta_0 + \mathbf{X}_1\beta_1 + \boldsymbol{\epsilon}, \quad E(\boldsymbol{\epsilon}) = \mathbf{0}, \quad \text{cov}(\boldsymbol{\epsilon}) = \sigma^2 \mathbf{I}_n,$$

其中 β_0 为截距项, β 为回归系数. β_0 和 β_1 的LS估计

$$\hat{\boldsymbol{\beta}}_1 = (\mathbf{X}'_1(\mathbf{I}_n - \mathbf{1}_n\mathbf{1}'_n/n)\mathbf{X}_1)^{-1}\mathbf{X}'_1(\mathbf{I}_n - \mathbf{1}_n\mathbf{1}'_n/n)\mathbf{y} = (\mathbf{X}'_C\mathbf{X}_C)^{-1}\mathbf{X}'_C\mathbf{y},$$

$$\hat{\beta}_0 = \mathbf{1}'_n(\mathbf{y} - \mathbf{X}_1\hat{\boldsymbol{\beta}}_1)/n = \bar{y} - \bar{x}_1'\hat{\boldsymbol{\beta}}_1,$$

这里 $\mathbf{X}_C = (\mathbf{I}_n - \mathbf{1}_n\mathbf{1}'_n/n)\mathbf{X}_1$ 为 \mathbf{X}_1 的（列）中心化后的矩阵.

参数分块的LS估计

中心化的线性模型

$$\mathbf{y} = \mathbf{1}_n \alpha + \mathbf{X}_C \boldsymbol{\beta}_1 + \boldsymbol{\epsilon}, \quad E(\boldsymbol{\epsilon}) = \mathbf{0}, \quad \text{cov}(\boldsymbol{\epsilon}) = \sigma^2 \mathbf{I}_n,$$

这里, $\alpha = \beta_0 + \bar{x}' \boldsymbol{\beta}_1$.

因为 $\mathbf{1}'_n \mathbf{X}_C = \mathbf{0}$, 于是 α 和 $\boldsymbol{\beta}_1$ 的LS估计

$$\hat{\alpha} = \bar{y},$$

$$\hat{\boldsymbol{\beta}}_1 = (\mathbf{X}'_C \mathbf{X}_C)^{-1} \mathbf{X}'_C \mathbf{y}.$$

注 $\hat{\boldsymbol{\beta}}_1$ 中心化的线性模型与非中心化线性模型下回归系数 $\boldsymbol{\beta}_1$ 的LS估计相同, 皆为 $\hat{\boldsymbol{\beta}}_1$.

样本分块的LS估计

- 对样本分块

假设观测数据被分块存储在 K 台机器上, 全模型可被分块为

$$\begin{pmatrix} \mathbf{y}_1 \\ \vdots \\ \mathbf{y}_K \end{pmatrix} = \begin{pmatrix} \mathbf{X}_1 \\ \vdots \\ \mathbf{X}_K \end{pmatrix} \boldsymbol{\beta} + \begin{pmatrix} \mathbf{e}_1 \\ \vdots \\ \mathbf{e}_K \end{pmatrix}. \quad (4.5)$$

假设 $\text{rk}(\mathbf{X}_k) = p$, 则全模型 $\boldsymbol{\beta}$ 的LS估计为

$$\hat{\boldsymbol{\beta}} = \left(\sum_{k=1}^K \mathbf{X}'_k \mathbf{X}_k \right)^{-1} \sum_{k=1}^K \mathbf{X}'_k \mathbf{y}_k$$

LS估计的分布式计算

假设观测数据被分块存储在 K 台机器上, 全模型可被分块为

$$\begin{pmatrix} \mathbf{y}_1 \\ \vdots \\ \mathbf{y}_K \end{pmatrix} = \begin{pmatrix} \mathbf{X}_1 \\ \vdots \\ \mathbf{X}_K \end{pmatrix} \boldsymbol{\beta} + \begin{pmatrix} \mathbf{e}_1 \\ \vdots \\ \mathbf{e}_K \end{pmatrix}. \quad (4.6)$$

假设 $\text{rk}(\mathbf{X}_k) = p$, 则全模型 $\boldsymbol{\beta}$ 的LS估计为

$$\hat{\boldsymbol{\beta}} = \left(\sum_{k=1}^K \mathbf{X}'_k \mathbf{X}_k \right)^{-1} \sum_{k=1}^K \mathbf{X}'_k \mathbf{y}_k$$

子模型

$$\mathbf{y}_k = \mathbf{X}_k \boldsymbol{\beta}_k + \mathbf{e}_k, \quad E(\mathbf{e}) = \mathbf{0}, \quad \text{cov}(\mathbf{e}) = \sigma^2 \mathbf{I}_{n_k} \quad (4.7)$$

的LS估计 $\hat{\boldsymbol{\beta}}_k = (\mathbf{X}'_k \mathbf{X}_k)^{-1} \mathbf{X}'_k \mathbf{y}_k$.

LS估计的分布式计算

记 $\mathbf{V}_k = \mathbf{X}'_k \mathbf{X}_k$. 注意到

$$\hat{\boldsymbol{\beta}} = \left(\sum_{k=1}^K \mathbf{X}'_k \mathbf{X}_k \right)^{-1} \sum_{k=1}^K \mathbf{X}'_k \mathbf{y}_k = \left(\sum_{k=1}^K \mathbf{V}_k \right)^{-1} \sum_{k=1}^K \mathbf{V}_k \hat{\boldsymbol{\beta}}_k,$$

于是, 在计算全模型 $\boldsymbol{\beta}$ 的 LS 估计时, 各台机器只需传输子模型的 LS 估计 $\hat{\boldsymbol{\beta}}_k$ 和矩阵 \mathbf{V}_k 到中央机器上即可, 无需传输原始数据.

关于分布式统计推断的研究综述, 参阅

Gao, Y., Liu, W. D., Wang, H. S., Wang, X. Z., X. Z., Yan, Y. B, Zhang, R. Q.
A review of distributed statistical inference. Statistical Theory and Related
Fields, 2022, 6: 89-99.

约束最小二乘估计

线性模型

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{e}, \quad E(\boldsymbol{e}) = \mathbf{0}, \quad \text{cov}(\boldsymbol{e}) = \sigma^2 \mathbf{I}_n,$$

约束条件：

$$\mathbf{H}\boldsymbol{\beta} = \mathbf{d}, \quad \text{即 } \mathbf{h}'_i \boldsymbol{\beta} = d_i, \quad i = 1, \dots, k.$$

其中 $\text{rk}(\mathbf{H}) = k$, $\mathcal{M}(\mathbf{H}') \subset \mathcal{M}(\mathbf{X}')$, $\mathbf{d} \in \mathcal{M}(\mathbf{H})$,

$$\mathbf{H} = \begin{pmatrix} \mathbf{h}'_1 \\ \vdots \\ \mathbf{h}'_k \end{pmatrix}, \quad \mathbf{d} = \begin{pmatrix} d_1 \\ \vdots \\ d_k \end{pmatrix}. \quad (4.8)$$

问题：在 k 个条件下求 $\boldsymbol{\beta}$ 使 $Q(\boldsymbol{\beta}) = \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2$ 达到最小值

约束最小二乘估计

为了应用Lagrange乘子法, 构造 辅助函数

$$\begin{aligned} F(\boldsymbol{\beta}, \boldsymbol{\lambda}) &= \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + 2 \sum_{i=1}^k \lambda_i (\mathbf{h}'_i \boldsymbol{\beta} - d_i) \\ &= \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + 2\boldsymbol{\lambda}'(\mathbf{H}\boldsymbol{\beta} - \mathbf{d}) \\ &= (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) + 2\boldsymbol{\lambda}'(\mathbf{H}\boldsymbol{\beta} - \mathbf{d}), \end{aligned}$$

其中 $\boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_k)'$ 为 Lagrange 乘子. 令 $\frac{\partial F(\boldsymbol{\beta}, \boldsymbol{\lambda})}{\partial \boldsymbol{\beta}} = \mathbf{0}$, 得

$$\mathbf{X}'\mathbf{X}\boldsymbol{\beta} = \mathbf{X}'\mathbf{y} - \mathbf{H}'\boldsymbol{\lambda}. \quad (4.9)$$

因为 $\mathcal{M}(\mathbf{H}') \subset \mathcal{M}(\mathbf{X}')$, 所以上方程关于 $\boldsymbol{\beta}$ 是相容的, 其解

$$\hat{\boldsymbol{\beta}}_{\mathbf{H}} = (\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'\mathbf{y} - (\mathbf{X}'\mathbf{X})^{-}\mathbf{H}'\hat{\boldsymbol{\lambda}}_{\mathbf{H}} = \hat{\boldsymbol{\beta}} - (\mathbf{X}'\mathbf{X})^{-}\mathbf{H}'\hat{\boldsymbol{\lambda}}_{\mathbf{H}}.$$

约束最小二乘估计

代入 $\mathbf{H}\beta = \mathbf{d}$, 得 $\mathbf{d} = \mathbf{H}\hat{\boldsymbol{\beta}}_{\mathbf{H}} = \mathbf{H}\hat{\boldsymbol{\beta}} - \mathbf{H}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}'\hat{\boldsymbol{\lambda}}_{\mathbf{H}}$, 等价地

$$\mathbf{H}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}'\hat{\boldsymbol{\lambda}}_{\mathbf{H}} = (\mathbf{H}\hat{\boldsymbol{\beta}} - \mathbf{d}). \quad (4.10)$$

这是一个关于 $\hat{\boldsymbol{\lambda}}_{\mathbf{H}}$ 的线性方程组. 因为 \mathbf{H} 的秩为 k , 且 $\mathcal{M}(\mathbf{H}') \subset \mathcal{M}(\mathbf{X}')$, 于是 $\mathbf{H}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}'$ 跟所包含广义逆的选择无关. 故可证它是 $k \times k$ 的可逆矩阵, 因而(4.10)有唯一解

$$\hat{\boldsymbol{\lambda}}_{\mathbf{H}} = (\mathbf{H}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}')^{-1}(\mathbf{H}\hat{\boldsymbol{\beta}} - \mathbf{d}).$$

将 $\hat{\boldsymbol{\lambda}}_{\mathbf{H}}$ 代入(4.9)得到

$$\hat{\boldsymbol{\beta}}_{\mathbf{H}} = \hat{\boldsymbol{\beta}} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}'(\mathbf{H}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}')^{-1}(\mathbf{H}\hat{\boldsymbol{\beta}} - \mathbf{d}).$$

约束最小二乘估计的性质

约束最小二乘估计 $\hat{\beta}_H$ 为是线性约束 $H\beta = d$ 下 β 的最小二乘解, 即

(a) $H\hat{\beta}_H = d$;

(b) 对一切满足 $H\beta = d$ 的 β , 都有 $\|y - X\beta\|^2 \geq \|y - X\hat{\beta}_H\|^2$.

证明 (a) 显然成立. (b) 的证明关键:

$$(y - X\hat{\beta})'X(\hat{\beta} - \beta) = y(I_n - P_X)X(\hat{\beta} - \beta) = 0,$$

$$(\hat{\beta} - \hat{\beta}_H)'X'X(\hat{\beta}_H - \beta) = \hat{\lambda}'(H\hat{\beta}_H - H\beta) = \hat{\lambda}'(d - d) = 0$$

$$\begin{aligned}\implies \|y - X\beta\|^2 &= \|y - X\hat{\beta}\|^2 + (\hat{\beta} - \beta)'X'X(\hat{\beta} - \beta) \\ &= \|y - X\hat{\beta}\|^2 + \|X(\hat{\beta} - \hat{\beta}_H)\|^2 + \|X(\hat{\beta}_H - \beta)\|^2 \\ &\geq \|y - X\hat{\beta}\|^2 + \|X(\hat{\beta} - \hat{\beta}_H)\|^2.\end{aligned}$$

定理4.3.1

对于线性模型, 设 \mathbf{H} 为 $k \times p$ 矩阵, $\text{rk}(\mathbf{H}) = k$, $\mathcal{M}(\mathbf{H}') \subset \mathcal{M}(\mathbf{X}')$, 且 $\mathbf{H}\beta = d$ 相容(即 $d \in \mathcal{M}(\mathbf{H})$), 则

(1) $\hat{\beta}_{\mathbf{H}} = \hat{\beta} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}'(\mathbf{H}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}')^{-1}(\mathbf{H}\hat{\beta} - d)$ 为 β 在线性约束条件 $\mathbf{H}\beta = d$ 下的约束LS解, $\mathbf{H}\hat{\beta}_{\mathbf{H}}$ 为 $\mathbf{H}\beta$ 的约束LS估计, 这里 $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'y$.

(2) 若 $\text{rk}(\mathbf{X}) = p$, 则

$$\hat{\beta}_{\mathbf{H}} = \hat{\beta} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}'(\mathbf{H}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}')^{-1}(\mathbf{H}\hat{\beta} - d)$$

为 β 的约束LS估计, 这里 $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'y$.

约束最小二乘估计

例4.3.1 在天文测量中, 对天空中三个星位点构成 $\triangle ABC$ 的三个内角 $\theta_1, \theta_2, \theta_3$ 进行测量. 用线性模型表示:

$$\begin{cases} y_1 = \theta_1 + e_1, \\ y_2 = \theta_2 + e_2, \\ y_3 = \theta_3 + e_3, \\ \theta_1 + \theta_2 + \theta_3 = \pi, \end{cases}$$

其中 $e_i, i = 1, 2, 3$ 表示测量误差. 假设它们满足Guass-Markov假设, 这就是一个带有约束条件的线性模型. 令

$\mathbf{y} = (y_1, y_2, y_3)', \boldsymbol{\beta} = (\theta_1, \theta_2, \theta_3)', \mathbf{X} = \mathbf{I}_3, \mathbf{H} = (1, 1, 1), \mathbf{b} = \pi$.

θ_i 的约束最小二乘估计为

$$\hat{\theta}_i = y_i - \frac{1}{3}(y_1 + y_2 + y_3 - \pi), i = 1, 2, 3.$$

约束最小二乘估计

定理4.3.2

在定理4.3.1假设下, 在参数区域 $\mathbf{H}\beta = \mathbf{d}$ 上,

$$\hat{\sigma}_{\mathbf{H}}^2 = \|\mathbf{y} - \mathbf{X}\hat{\beta}_{\mathbf{H}}\|^2 / (n - r + k)$$

是 σ^2 的无偏估计.

证明 注意到 $E\|\mathbf{y} - \mathbf{X}\hat{\beta}_{\mathbf{H}}\|^2 = E\|\mathbf{y} - \mathbf{X}\hat{\beta}\|^2 + E\|\mathbf{X}(\hat{\beta} - \hat{\beta}_{\mathbf{H}})\|^2$, 其中,
 $E\|\mathbf{y} - \mathbf{X}\hat{\beta}\|^2 = (n - r)\sigma^2$,

$$\begin{aligned} E\|\mathbf{X}(\hat{\beta} - \hat{\beta}_{\mathbf{H}})\|^2 &= E(\mathbf{H}\hat{\beta} - \mathbf{d})'(\mathbf{H}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}')^{-1}(\mathbf{H}\hat{\beta} - \mathbf{d}) \\ &= \text{tr}[(\mathbf{H}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}')^{-1}\text{Cov}(\mathbf{H}\hat{\beta})] = k\sigma^2, \end{aligned}$$

定理得证.

约束最小二乘估计

定理4.3.3

对于正态Guass-Markov 线性模型, 若定理4.3.1假设成立, 则 $\widehat{\boldsymbol{\beta}}_{\mathbf{H}}$ 和 $(n - r + k)\widehat{\sigma}_{\mathbf{H}}^2/n$ 分别为 $\mathbf{H}\boldsymbol{\beta}$ 和 σ^2 在线性约束 $\mathbf{H}\boldsymbol{\beta} = \mathbf{d}$ 下的约束ML估计.

证明 记 $\mu = \mathbf{X}\boldsymbol{\beta}$, 考虑 μ 和 σ^2 的对数似然函数

$$\log L(\boldsymbol{\mu}, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \|\mathbf{y} - \boldsymbol{\mu}\|^2. \quad (4.11)$$

不难看出: 在 $\mathbf{H}\boldsymbol{\beta} = \mathbf{d}$ 下 $\boldsymbol{\mu} = \mathbf{X}\boldsymbol{\beta}$ 的ML估计为

$$\begin{aligned} \widehat{\boldsymbol{\mu}}_{\mathbf{H}} &= \arg \min_{\substack{\boldsymbol{\mu} = \mathbf{X}\boldsymbol{\beta} \\ \mathbf{H}\boldsymbol{\beta} = \mathbf{d}}} \|\mathbf{y} - \boldsymbol{\mu}\|^2 = \mathbf{X}\widehat{\boldsymbol{\beta}}_{\mathbf{H}}, \end{aligned}$$

将其带入(4.11), 极大化 $\log L(\widehat{\boldsymbol{\mu}}_{\mathbf{H}}, \sigma^2)$ 得 $\widehat{\sigma}_{\mathbf{H}}^2 = \frac{\|\mathbf{y} - \mathbf{X}\widehat{\boldsymbol{\beta}}_{\mathbf{H}}\|^2}{n} = (n - r + k)\widehat{\sigma}_{\mathbf{H}}^2/n$.

广义最小二乘估计

线性模型

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad E(\mathbf{e}) = \mathbf{0}, \quad \text{Cov}(\mathbf{e}) = \sigma^2 \boldsymbol{\Sigma} \quad (4.12)$$

其中 $\boldsymbol{\Sigma} > \mathbf{0}$. 考虑参数 $\boldsymbol{\beta}, \sigma^2$ 的估计问题.

- 采用模型变换.

用 $\boldsymbol{\Sigma}^{-1/2}$ 左乘模型(4.12), 得Guass-Markov模型

$$\tilde{\mathbf{y}} = \tilde{\mathbf{X}}\boldsymbol{\beta} + \mathbf{u},$$

其中, $\tilde{\mathbf{y}} = \boldsymbol{\Sigma}^{-1/2}\mathbf{y}, \quad \tilde{\mathbf{X}} = \boldsymbol{\Sigma}^{-1/2}\mathbf{X}, \quad \mathbf{u} = \boldsymbol{\Sigma}^{-1/2}\mathbf{e},$

$$E(\mathbf{u}) = \mathbf{0}, \quad \text{Cov}(\mathbf{u}) = \sigma^2 \mathbf{I}_n.$$

广义最小二乘估计

- 针对变换后的模型, 采用LS法得

$$\boldsymbol{\beta}^* = (\tilde{\mathbf{X}}'\tilde{\mathbf{X}})^{-1}\tilde{\mathbf{X}}'\tilde{\mathbf{y}} = (\mathbf{X}'\Sigma^{-1}\mathbf{X})^{-1}\mathbf{X}'\Sigma^{-1}\mathbf{y}$$

$$\sigma^{2*} = \|\tilde{\mathbf{y}} - \tilde{\mathbf{X}}\boldsymbol{\beta}^*\|^2/(n-r) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}^*)'\Sigma^{-1}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}^*)/(n-r).$$

称 $\boldsymbol{\beta}^*$ 和 σ^{2*} 为模型(4.12)的广义最小二乘(GLS)估计.

定理4.4.1

对任一可估函数 $\mathbf{c}'\boldsymbol{\beta}$, GLS估计 $\mathbf{c}'\boldsymbol{\beta}^*$ 为其惟一的BLU估计, 其方差为 $\sigma^2\mathbf{c}'(\mathbf{X}'\Sigma^{-1}\mathbf{X})^{-1}\mathbf{c}$; σ^{2*} 为 σ^2 的无偏估计, 其中

$$\boldsymbol{\beta}^* = (\mathbf{X}'\Sigma^{-1}\mathbf{X})^{-1}\mathbf{X}'\Sigma^{-1}\mathbf{y}$$

$$\sigma^{2*} = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}^*)'\Sigma^{-1}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}^*)/(n-r).$$

广义最小二乘估计

定理4.4.2

在线性模型 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{e}$ 下, 若 $\boldsymbol{e} \sim N(0, \sigma^2 \Sigma)$, $\Sigma (> 0)$ 已知, 则

(1) 对任一可估函数 $\mathbf{c}'\boldsymbol{\beta}$, $\mathbf{c}'\boldsymbol{\beta}^*$ 为 $\mathbf{c}'\boldsymbol{\beta}$ 的ML估计和唯一MVU估计, 且

$$\mathbf{c}'\boldsymbol{\beta}^* \sim N(\mathbf{c}'\boldsymbol{\beta}, \sigma^2 \mathbf{c}' (\mathbf{X}' \Sigma^{-1} \mathbf{X})^{-1} \mathbf{c}).$$

(2) $\frac{n-r}{n}\sigma^2$ 为 σ^2 的ML估计, σ^2 为 σ^2 的唯一MVU估计, 且

$$(n-r)\sigma^2 / \sigma^2 \sim \chi_{n-r}^2.$$

(3) $\mathbf{c}'\boldsymbol{\beta}^*$ 与 σ^2 相互独立.

GLS估计和LS估计的比较

对于线性模型

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{e}, \quad E(\boldsymbol{e}) = \mathbf{0}, \quad \text{Cov}(\boldsymbol{e}) = \sigma^2 \boldsymbol{\Sigma} > \mathbf{0},$$

可估函数 $\mathbf{c}'\boldsymbol{\beta}$ 的LS估计和GLS估计

$$\mathbf{c}'\hat{\boldsymbol{\beta}} = \mathbf{c}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}, \quad \mathbf{c}'\boldsymbol{\beta}^* = \mathbf{c}'(\mathbf{X}'\boldsymbol{\Sigma}^{-1}\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\Sigma}^{-1}\mathbf{y}.$$

- 两者都是无偏的, $E(\mathbf{c}'\hat{\boldsymbol{\beta}}) = \mathbf{c}'\boldsymbol{\beta} = E(\mathbf{c}'\boldsymbol{\beta}^*)$;
- GLS估计的方差更小, 由定理4.4.1, 直接有

$$\text{Var}(\mathbf{c}'\boldsymbol{\beta}^*) \leq \text{Var}(\mathbf{c}'\hat{\boldsymbol{\beta}}).$$

广义最小二乘估计

例 用一种精密仪器在两个实验室对同一个物 μ 分别进行测量, 假设数据模型如下

$$y_{1i} = \mu + e_{1i}, \quad i = 1, \dots, n_1,$$

$$y_{2i} = \mu + e_{2i}, \quad i = 1, \dots, n_2.$$

由于两个实验室的客观条件及精密仪器的精度不同, 故测量误差的方差不等. 设

$$\text{Var}(e_{1i}) = \sigma_1^2 \neq \text{Var}(e_{2i}) = \sigma_2^2.$$

记 $\mathbf{y} = (y_{11}, \dots, y_{1n_1}, y_{21}, \dots, y_{2n_2})'$,

$$\mathbf{e} = (e_{11}, \dots, e_{1n_1}, e_{21}, \dots, e_{2n_2})'.$$

广义最小二乘估计

则

$$\text{Cov}(\boldsymbol{e}) = \begin{pmatrix} \sigma_1^2 \mathbf{I}_{n_1} & 0 \\ 0 & \sigma_2^2 \mathbf{I}_{n_2} \end{pmatrix} = \sigma_2^2 \begin{pmatrix} \theta \mathbf{I}_{n_1} & 0 \\ 0 & \mathbf{I}_{n_2} \end{pmatrix} = \sigma_2^2 \boldsymbol{\Sigma}.$$

假设 $\theta = \sigma_1^2 / \sigma_2^2$ 已知, 则 μ 的GLS估计

$$\mu^* = \left(\frac{n_1}{\theta} + n_2 \right)^{-1} \left(\frac{\sum_{i=1}^{n_1} y_{1i}}{\theta} + \sum_{i=1}^{n_2} y_{2i} \right) = v_1 \bar{y}_1 + v_2 \bar{y}_2,$$

这里, $v_1 = 1 - v_2$,

$$v_2 = \frac{w_2}{w_1 + w_2}, \quad w_i = \frac{1}{\text{Var}(\bar{y}_i)} = \frac{n_i}{\sigma_i^2}.$$

最小二乘统一理论*

线性模型

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon} \quad E(\boldsymbol{\epsilon}) = \mathbf{0}, \quad \text{Cov}(\boldsymbol{\epsilon}) = \sigma^2 \boldsymbol{\Sigma}, \quad (4.13)$$

如果 $|\boldsymbol{\Sigma}| = 0$, 则称该模型为奇异线性模型.

引理4.5.1

对于线性模型(4.13), 不管 $\boldsymbol{\Sigma} > \mathbf{0}$ 或 $\boldsymbol{\Sigma} \geq \mathbf{0}$, $\mathbf{y} \in \mathcal{M}(\boldsymbol{\Sigma}, \mathbf{X})$ 总是成立.

引理4.5.2

记 $\mathbf{T} = \boldsymbol{\Sigma} + \mathbf{X}\mathbf{U}\mathbf{X}'$, 其中 $\mathbf{U} \geq \mathbf{0}$, $\text{rk}(\mathbf{T}) = \text{rk}(\boldsymbol{\Sigma}, \mathbf{X})$, 则总有

(1) $\mathcal{M}(\mathbf{T}) = \mathcal{M}(\boldsymbol{\Sigma}, \mathbf{X})$.

(2) $\mathbf{X}'\mathbf{T}^{-}\mathbf{X}$, $\mathbf{X}'\mathbf{T}^{-}\mathbf{y}$ 和 $(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})\mathbf{T}^{-}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$ 都与广义逆 \mathbf{T}^{-} 的选择无关.

最小二乘统一理论

引理4.5.3

对于线性模型(4.13), 可估函数 $c'\beta$ 的一个无偏估计 $a'y$ 为BLU估计, 当且仅当它满足

$$\text{Cov}(a'y, b'y) = 0,$$

这里 $b'y$ 为零的任一无偏估计, 即 $E(b'y) = 0$.

证明 设 $l'y$ 为 $c'\beta$ 的任一无偏估计, 则 l 一定可表示为 $l = a + b$, 对某个满足 $X'b = 0$ 的 b . 于是

$$\text{Var}(l'y) = \text{Var}(a'y) + \text{Var}(b'y) + 2\text{Cov}(a'y, b'y). \quad (4.14)$$

充分性得证.

最小二乘统一理论

下面用反证法来证明必要性.

设 $\mathbf{a}'\mathbf{y}$ 为 $\mathbf{c}'\beta$ 的BLU估计. 若存在一个 \mathbf{b}_0 , 满足 $\mathbf{X}'\mathbf{b}_0 = \mathbf{0}$, 但有

$$\text{Cov}(\mathbf{a}'\mathbf{y}, \mathbf{b}_0'\mathbf{y}) = d \neq 0,$$

不妨设 $d < 0$. 若不然, 只需取 $-\mathbf{b}_0$ 代替 \mathbf{b}_0 , 就可化为 $d < 0$ 的情形.
用 $\mathbf{b} = \alpha\mathbf{b}_0$ 代替(4.14) 中的 \mathbf{b} ,

$$f(\alpha) = \text{Var}(\mathbf{l}'\mathbf{y}) - \text{Var}(\mathbf{a}'\mathbf{y}) = \alpha(\alpha\mathbf{b}_0'\Sigma\mathbf{b}_0 + 2d).$$

易证当 $\alpha \in (0, -2\mathbf{b}/\mathbf{b}_0'\Sigma\mathbf{b}_0)$ 时, $f(\alpha) < 0$, 即

$$\text{Var}(\mathbf{l}'\mathbf{y}) < \text{Var}(\mathbf{a}'\mathbf{y}),$$

这与 $\mathbf{a}'\mathbf{y}$ 为BLU估计相矛盾. 引理得证.

最小二乘统一理论

定理4.5.1

对于线性模型(4.13)和任一可估函数 $\mathbf{c}'\boldsymbol{\beta}$ 有

(1) $\mathbf{c}'\boldsymbol{\beta}^* = \mathbf{c}'(\mathbf{X}'\mathbf{T}^{-}\mathbf{X})^{-}\mathbf{X}'\mathbf{T}^{-}\mathbf{y}$ 为 $\mathbf{c}'\boldsymbol{\beta}$ 的BLU估计；

(2) $\text{Var}(\mathbf{c}'\boldsymbol{\beta}^*) = \sigma^2 \mathbf{c}' [(\mathbf{X}'\mathbf{T}^{-}\mathbf{X})^{-} - \mathbf{U}] \mathbf{c}$.

(3) $\sigma^{2*} = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}^*)'\mathbf{T}^{-}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}^*) / (\text{rk}(\mathbf{T}) - \text{rk}(\mathbf{X}))$ 为 σ^2 的无偏估计.

推论4.5.1

对于线性模型(4.13) 和任一可估函数 $\mathbf{c}'\boldsymbol{\beta}$, 若 $\mathcal{M}(\mathbf{X}) \subset \mathcal{M}(\Sigma)$, 则

(1) $\mathbf{c}'\boldsymbol{\beta}^* = \mathbf{c}'(\mathbf{X}'\Sigma^{-}\mathbf{X})^{-}\mathbf{X}'\Sigma^{-}\mathbf{y}$ 为 $\mathbf{c}'\boldsymbol{\beta}$ 的BLU估计；

(2) $\text{Var}(\mathbf{c}'\boldsymbol{\beta}^*) = \sigma^2 \mathbf{c}'(\mathbf{X}'\Sigma^{-}\mathbf{X})^{-}\mathbf{c}$, 并且所有表达式与所包含的广义逆选择无关.

Panel模型

Panel模型

$$y_{it} = \beta_0 + x_{it1}\beta_1 + \cdots + x_{itk}\beta_k + \mu_i + e_{it}, \quad (4.15)$$
$$i = 1, 2, \dots, N, \quad t = 1, 2, \dots, T,$$

这里 y_{it} 为第*i*个个体在时刻*t*的观测值, μ_i 为第*i*个个体的效应, 与随机误差 e_{it} 为随机误差不相关, 且

$$E(e_{it}) = 0, \quad \text{Var}(e_{it}) = \sigma_e^2, \quad E(\mu_i) = 0, \quad \text{Var}(\mu_i) = \sigma_\mu^2.$$

记 $\boldsymbol{\beta} = (\beta_1, \dots, \beta_k)'$, $\boldsymbol{\mu} = (\mu_1, \dots, \mu_N)'$, $\mathbf{x}_{it} = (x_{it1}, \dots, x_{itk})'$,

$$\mathbf{y} = (y_{11}, \dots, y_{1T}, y_{21}, \dots, y_{2T}, \dots, y_{NT})',$$

$$\mathbf{X} = (\mathbf{x}_{11}, \dots, \mathbf{x}_{1T}, \mathbf{x}_{21}, \dots, \mathbf{x}_{2T}, \dots, \mathbf{x}_{NT})',$$

$$\mathbf{e} = (e_{11}, \dots, e_{1T}, e_{21}, \dots, e_{2T}, \dots, e_{NT})'.$$

Panel模型

- 模型矩阵形式：

$$\mathbf{y} = \mathbf{1}_{NT}\beta_0 + \mathbf{X}\boldsymbol{\beta} + \mathbf{u},$$

这里, $\mathbf{u} = (\mathbf{I}_N \otimes \mathbf{1}_T)\boldsymbol{\mu} + \mathbf{e}$. 易证协方差阵的谱分解:

$$\text{Cov}(\mathbf{u}) = \sigma_1^2 \mathbf{P}_1 + \sigma_e^2 \mathbf{Q} + \sigma_1^2 \mathbf{J}_{NT},$$

这里,

$$\mathbf{P}_1 = (\mathbf{I}_N - \mathbf{J}_N) \otimes \mathbf{J}_T,$$

$$\mathbf{Q} = \mathbf{I}_N \otimes (\mathbf{I}_T - \mathbf{J}_T),$$

$$\mathbf{J}_k = \mathbf{1}_k \mathbf{1}'_k / k.$$

Panel模型的约简估计

- \mathbf{P}_1 左乘模型的等号两边，得约见模型：

$$\mathbf{P}_1\mathbf{y} = \mathbf{P}_1\mathbf{X}\beta + \mathbf{P}_1\mathbf{u}.$$

称其的BLU估计为Between估计：

$$\widehat{\boldsymbol{\beta}}_B = (\mathbf{X}'\mathbf{P}_1\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_1\mathbf{y}$$

- 用 $\mathbf{Q} = \mathbf{I}_N \otimes (\mathbf{I}_T - \mathbf{J}_T)$ 左乘原模型得变换模型：

$$\mathbf{Q}\mathbf{y} = \mathbf{Q}\mathbf{X}\beta + \mathbf{Q}\mathbf{e}$$

的BLU估计分别为Within估计：

$$\widehat{\boldsymbol{\beta}}_W = (\mathbf{X}'\mathbf{Q}\mathbf{X})^{-1}\mathbf{X}'\mathbf{Q}\mathbf{y}$$

最小二乘估计的稳健性

线性模型

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad E(\boldsymbol{\epsilon}) = \mathbf{0}, \quad \text{Cov}(\boldsymbol{\epsilon}) = \sigma^2 \boldsymbol{\Sigma}, \quad (4.13)$$

这里 $\boldsymbol{\Sigma} \geq \mathbf{0}$ 已知. 对任一可估函数 $\mathbf{c}'\boldsymbol{\beta}$, 它的LS估计为

$$\mathbf{c}'\hat{\boldsymbol{\beta}} = \mathbf{c}'(\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'\mathbf{y}.$$

研究LS估计关于协方差阵的稳健性, 即研究 $\boldsymbol{\Sigma}$ 满足什么结构时,

$$\mathbf{c}'\hat{\boldsymbol{\beta}} = \mathbf{c}'\boldsymbol{\beta}^*, \quad (4.14)$$

最小二乘估计的稳健性

记 \mathbf{Z} 为 $n \times (n-r)$ 且秩为 $n-r$ 的矩阵, 满足 $\mathbf{X}'\mathbf{Z} = \mathbf{0}$, 这里 $r = \text{rk}(\mathbf{X})$.

定理4.6.1

对于线性模型(4.13)和任一可估函数 $\mathbf{c}'\boldsymbol{\beta}$, (4.14)成立当且仅当下列条件之一成立.

- (1) $\mathbf{X}'\Sigma\mathbf{Z} = \mathbf{0}$;
- (2) $\Sigma = \mathbf{X}\Lambda_1\mathbf{X}' + \mathbf{Z}\Lambda_2\mathbf{Z}'$;
- (3) $\Sigma = \mathbf{X}\mathbf{D}_1\mathbf{X}' + \mathbf{Z}\mathbf{D}_2\mathbf{Z}' + \mathbf{I}_n$,

其中 $\Lambda_1, \Lambda_2, \mathbf{D}_1$ 和 \mathbf{D}_2 为任意对称阵, 但使 $\Sigma \geq \mathbf{0}$.

证明留给学生自学.

最小二乘估计的稳健性

例 误差均匀相关模型(error uniform correlation models).

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon} \quad E(\boldsymbol{\epsilon}) = \mathbf{0},$$

误差向量 $\boldsymbol{\epsilon}$ 的协方差阵具有如下形式

$$\text{Cov}(\boldsymbol{\epsilon}) = \sigma^2 \begin{pmatrix} 1 & \rho & \cdots & \rho \\ \rho & 1 & \cdots & \rho \\ \vdots & \vdots & \ddots & \vdots \\ \rho & \rho & \cdots & 1 \end{pmatrix} = \sigma^2[\rho \mathbf{1}_n \mathbf{1}'_n + (1 - \rho) \mathbf{I}_n].$$

若 \mathbf{X} 的第一列全为1, 即模型包含常数项, 则 $\mathbf{X}'\text{Cov}(\boldsymbol{\epsilon})\mathbf{Z} = \mathbf{0}$, 故任一可估函数 $\mathbf{c}'\boldsymbol{\beta}$ 的LS估计仍为BLU估计.

最小二乘估计的稳健性

定理4.6.2

对于线性模型(4.13) 和任一可估函数 $\mathbf{c}'\boldsymbol{\beta}$, (4.14) 成立当且仅当下列条件之一成立.

- (1) $\Sigma \mathbf{X} = \mathbf{X}\mathbf{B}$, 对某矩阵 \mathbf{B} ;
- (2) $\mathcal{M}(\mathbf{X})$ 由 Σ 的 $r = \text{rk}(\mathbf{X})$ 个特征向量张成;
- (3) $\mathbf{P}_{\mathbf{X}}\Sigma$ 为对称阵, 其中 $\mathbf{P}_{\mathbf{X}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$.

证明留给学生自学.

最小二乘估计的稳健性

例 考虑单向分类随机模型

$$y_{ij} = \mu + \alpha_i + e_{ij}, \quad i = 1, \dots, a, j = 1, \dots, b,$$

这里 μ 为固定效应, α_i 为随机效应, e_{ij} 为随机误差, $\text{Cov}(\alpha_i, e_{ij}) = 0$, $\text{Var}(\alpha_i) = \sigma_\alpha^2$, $\text{Var}(e_{ij}) = \sigma_e^2$. 记 $n = ab$, $\mathbf{X} = \mathbf{1}_n$, $\mathbf{U} = \mathbf{I}_a \otimes \mathbf{1}_b$.

矩阵形式

$$\mathbf{y} = \mathbf{X}\mu + \mathbf{U}\alpha + \mathbf{e},$$

$$\text{Cov}(\mathbf{y}) = \sigma_\alpha^2 \mathbf{U} \mathbf{U}' + \sigma_e^2 \mathbf{I}_n = \sigma_\alpha^2 (\mathbf{I}_a \otimes \mathbf{1}_b \mathbf{1}_b') + \sigma_e^2 \mathbf{I}_n \stackrel{\triangle}{=} \Sigma(\sigma^2).$$

根据矩阵 \mathbf{Z} 的定义 $\mathbf{X}'\mathbf{Z} = \mathbf{1}_n' \mathbf{Z} = \mathbf{0}$, 所以 $\mathbf{X}'\Sigma\mathbf{Z} = \mathbf{0}$. 依定理 4.6.1, 固定效应 μ 的 LS 估计 $\hat{\mu} = \bar{y}_{..}$ 是 μ 的 BLU 估计.

两步估计

考虑一般线性模型

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad E(\mathbf{e}) = \mathbf{0}, \quad \text{Cov}(\mathbf{e}) = \Sigma(\theta), \quad (4.18)$$

这里 \mathbf{y} 为 $n \times 1$ 观测向量, \mathbf{X} 为 $n \times p$ 设计阵, $\boldsymbol{\beta}$ 为 $p \times 1$ 未知参数向量, \mathbf{e} 为 $n \times 1$ 随机误差, $\boldsymbol{\theta} = (\theta_1, \dots, \theta_m)$ 也是未知参数向量. 设 $\Sigma(\boldsymbol{\theta}) > 0$ 对一切 $\boldsymbol{\theta}$ 成立.

- 当 $\boldsymbol{\theta}$ 已知时, 对任一可估函数 $\mathbf{c}'\boldsymbol{\beta}$, 当 $\boldsymbol{\theta}$ 已知时, $\mathbf{c}'\hat{\boldsymbol{\beta}}(\boldsymbol{\theta})$ 就是它的 GLS 估计, 也是 BLU 估计, 其中,

$$\hat{\boldsymbol{\beta}}(\boldsymbol{\theta}) = (\mathbf{X}'\Sigma^{-1}(\boldsymbol{\theta})\mathbf{X})^{-1}\mathbf{X}'\Sigma^{-1}(\boldsymbol{\theta})\mathbf{y}.$$

两步估计

- 当 θ 未知时, $c'\hat{\beta}(\theta)$ 就不再是一个可行估计.

此时, 若可得到 θ 的一个估计 $\hat{\theta}$, 将 $\hat{\beta}(\theta)$ 中 θ 用估计代替, 便得到 $c'\beta$ 的一个两步估计 $c'\hat{\beta}(\hat{\theta})$.

定理4.7.1

对于线性模型(4.18), 假设 e 的分布关于原点是对称的. 设 $\hat{\theta} = \hat{\theta}(y)$ 是 θ 的一个估计, 它是 y 的偶函数且具有变换不变性. 设 $c'\beta$ 为任一可估函数, 若 $E(c'\hat{\beta}(\hat{\theta}))$ 存在, 则两步估计 $c'\hat{\beta}(\hat{\theta})$ 是 $c'\beta$ 的无偏估计, 即

$$E(c'\hat{\beta}(\hat{\theta})) = c'\beta.$$

证明留给学生自学.

两步估计

例 Panel模型

$$\mathbf{y} = \mathbf{1}_{NT}\beta_0 + \mathbf{X}\boldsymbol{\beta} + \mathbf{u}, \quad \text{Cov}(\mathbf{u}) = \sigma_1^2 \mathbf{P}_1 + \sigma_e^2 \mathbf{Q} + \sigma_1^2 \mathbf{J}_{NT},$$

应用Between估计和Within估计, 可得到 σ_1^2 和 σ_e^2 的无偏估计:

$$s_1^2 = \hat{\mathbf{u}}_1' \mathbf{P}_1 \hat{\mathbf{u}}_1 / (N - k - 1),$$

$$s_2^2 = (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}_{\mathbf{W}})' \mathbf{Q} (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}_{\mathbf{W}}) / (N(T - 1) - k).$$

可证明两步估计

$$\hat{\boldsymbol{\beta}}(s^2) = \left(\frac{\mathbf{B}}{s_1^2} + \frac{\mathbf{W}}{s_2^2} \right)^{-1} \left(\frac{\mathbf{X}' \mathbf{P}_1 \mathbf{y}}{s_1^2} + \frac{\mathbf{X}' \mathbf{Q} \mathbf{y}}{s_2^2} \right)$$

是 $\boldsymbol{\beta}$ 的无偏估计, 这里 $s^2 = (s_1^2, s_2^2)'$.

两步估计

- 两步估计 $\tilde{\beta}$ 的均方误差矩阵(MSEM)

为符号简单, 记 $\Sigma(\theta) = \Sigma$,

$$\begin{aligned}\beta^* &= (\mathbf{X}'\Sigma^{-1}\mathbf{X})^{-1}\mathbf{X}'\Sigma^{-1}\mathbf{y}, \\ \tilde{\beta} &= (\mathbf{X}'\Sigma^{-1}(\hat{\theta})\mathbf{X})^{-1}\mathbf{X}'\Sigma^{-1}(\hat{\theta})\mathbf{y}.\end{aligned}$$

定理4.7.3

设 $e \sim N_n(\mathbf{0}, \sigma^2\Sigma)$, 则

$$\text{MSEM}(\tilde{\beta}) = \text{Cov}(\beta^*) + E(\mathbf{b}\mathbf{b}'),$$

这里 $\mathbf{b} = \tilde{\beta} - \beta^*$.

协方差改进法

MVU估计的判定定理(陈希孺, 1999)

参数 θ 的一个无偏估计 T 为MVU估计, 当且仅当对零的任一无偏估计 U 和一切 $\theta \in \Theta$, 都有

$$\text{Cov}(T, U) = 0,$$

这里 Θ 为参数空间, $\text{var}(T) < \infty$, $\text{var}(U) < \infty$.

这就是说,一个无偏估计要具有最小方差当且仅当它跟零的所有无偏估计都不相关.

- 协方差改进法(Rao,1967): 利用 U_0 与 T 的相关性构造两者的一个线性组合, 使其为 θ 的无偏估计, 且比 T 具有更小方差.

协方差改进法

定理4.8.1

设 θ 为 $p \times 1$ 未知参数, 统计量 \mathbf{T}_1 和 \mathbf{T}_2 满足 $E(\mathbf{T}_1) = \boldsymbol{\theta}$, $E(\mathbf{T}_2) = \mathbf{0}$,

$$\text{Cov} \begin{pmatrix} \mathbf{T}_1 \\ \mathbf{T}_2 \end{pmatrix} = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \triangleq \Sigma.$$

假定 $\Sigma > \mathbf{0}$, $\Sigma_{12} \neq \mathbf{0}$. 则在线性估计类

$$\mathbf{A} = \left\{ \mathbf{T} = \mathbf{A}_1 \mathbf{T}_1 + \mathbf{A}_2 \mathbf{T}_2, \mathbf{A}_1 \text{ 和 } \mathbf{A}_2 \text{ 为非随机阵}, E(\mathbf{T}) = \boldsymbol{\theta} \right\},$$

$\boldsymbol{\theta}$ 的BLU 估计为

$$\boldsymbol{\theta}^* = \mathbf{T}_1 - \Sigma_{12} \Sigma_{22}^{-1} \mathbf{T}_2,$$

且 $\text{Cov}(\boldsymbol{\theta}^*) = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \leq \Sigma_{11} = \text{Cov}(\mathbf{T}_1)$.

协方差改进法

证明 将定理的条件用线性模型表示, 即为

$$\begin{pmatrix} \mathbf{T}_1 \\ \mathbf{T}_2 \end{pmatrix} = \begin{pmatrix} \mathbf{I}_n \\ \mathbf{0} \end{pmatrix} \boldsymbol{\theta} + \boldsymbol{e}, \quad \boldsymbol{e} \sim (\mathbf{0}, \boldsymbol{\Sigma}),$$

易验证 $\boldsymbol{\theta}^*$ 为该模型中 $\boldsymbol{\theta}$ 的 BLU 估计. 其它结论显然, 定理证毕.

- 称估计 $\boldsymbol{\theta}^* = \mathbf{T}_1 - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\mathbf{T}_2$ 为协方差改进估计.
- 使用了 \mathbf{T}_2 和 \mathbf{T}_1 的相关性所带来的附加信息, 对协方差阵的影响:

$$\text{Cov}(\boldsymbol{\theta}^*) - \text{Cov}(\mathbf{T}_1) = -\boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21} \leq \mathbf{0}.$$

- 如果 $\boldsymbol{\Sigma}_{12} = \mathbf{0}$, 这时 \mathbf{T}_2 与 \mathbf{T}_1 不相关, 自然 \mathbf{T}_2 也就没有任何改进 \mathbf{T}_1 的附加信息.

协方差改进估计

例 考虑一般线性回归模型

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad E(\boldsymbol{\epsilon}) = \mathbf{0}, \quad \text{Cov}(\boldsymbol{\epsilon}) = \sigma^2 \boldsymbol{\Sigma} > \mathbf{0},$$

这里 $\text{rk}(\mathbf{X}) = p$. 取 $\mathbf{T}_1 = \widehat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$, $\mathbf{T}_2 = \mathbf{Z}'\mathbf{y}$, 这里 \mathbf{Z} 满足 $\mathbf{X}'\mathbf{Z} = \mathbf{0}$, 且 $\text{rk}(\mathbf{Z}) = n - p$, 则 $E(\mathbf{T}_1) = E(\widehat{\boldsymbol{\beta}}) = \boldsymbol{\beta}$, $E(\mathbf{T}_2) = \mathbf{0}$,

$$\text{Cov} \begin{pmatrix} \mathbf{T}_1 \\ \mathbf{T}_2 \end{pmatrix} = \sigma^2 \begin{pmatrix} (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\Sigma}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} & (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\Sigma}\mathbf{Z} \\ \mathbf{Z}'\boldsymbol{\Sigma}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} & \mathbf{Z}'\boldsymbol{\Sigma}\mathbf{Z} \end{pmatrix}.$$

假定 $\mathbf{X}'\boldsymbol{\Sigma}\mathbf{Z} \neq \mathbf{0}$, 协方差改进估计

$$\widetilde{\boldsymbol{\beta}} = \widehat{\boldsymbol{\beta}} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\Sigma}\mathbf{Z}(\mathbf{Z}'\boldsymbol{\Sigma}\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{y} = \boldsymbol{\beta}^*,$$

即 $\boldsymbol{\beta}$ 的 BLU 估计 $\boldsymbol{\beta}^*$ 是从 LS 估计经过一次协方差改进得到的.

协方差改进估计

例 带线性约束的线性回归模型

$$\begin{cases} \mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{e}, & E(\boldsymbol{e}) = \mathbf{0}, \quad \text{Cov}(\boldsymbol{e}) = \sigma^2 \mathbf{I}_n, \\ \mathbf{H}\boldsymbol{\beta} = \mathbf{d}, \end{cases}$$

这里 \mathbf{H} 为 $m \times p$ 矩阵, $\text{rk}(\mathbf{H}) = m$, 且 $\mathbf{H}\boldsymbol{\beta} = \mathbf{d}$ 是相容的. 取 $\mathbf{T}_1 = \widehat{\boldsymbol{\beta}}$,
 $\mathbf{T}_2 = \mathbf{H}\widehat{\boldsymbol{\beta}} - \mathbf{d}$. 在约束参数区域 $\mathbf{H}\boldsymbol{\beta} = \mathbf{d}$ 上, $E(\mathbf{T}_2) = \mathbf{0}$,

$$\text{Cov} \begin{pmatrix} \mathbf{T}_1 \\ \mathbf{T}_2 \end{pmatrix} = \sigma^2 \begin{pmatrix} (\mathbf{X}'\mathbf{X})^{-1} & (\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}' \\ \mathbf{H}(\mathbf{X}'\mathbf{X})^{-1} & \mathbf{H}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}' \end{pmatrix}.$$

应用定理4.8.1, 得到协方差改进估计

$$\widehat{\boldsymbol{\beta}}_H = \widehat{\boldsymbol{\beta}} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}'(\mathbf{H}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}')^{-1}(\mathbf{H}\widehat{\boldsymbol{\beta}} - \mathbf{d}),$$

它正是 $\boldsymbol{\beta}$ 的约束LS估计.

协方差改进估计

例 带随机形式附加信息的线性回归模型

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{e}, \quad E(\boldsymbol{e}) = \mathbf{0}, \quad \text{Cov}(\boldsymbol{e}) = \sigma^2 \mathbf{I}_n,$$

$$\mathbf{u} = \mathbf{H}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad E(\boldsymbol{\varepsilon}) = \mathbf{0}, \quad \text{Cov}(\boldsymbol{\varepsilon}) = \mathbf{W},$$

这里 $\mathbf{W} > \mathbf{0}$ 是已知矩阵, $\boldsymbol{\varepsilon}$ 和 \boldsymbol{e} 不相关. 取 $T_1 = \hat{\boldsymbol{\beta}}$, $T_2 = \mathbf{u} - \mathbf{H}\hat{\boldsymbol{\beta}}$.
若 σ^2 已知, 则所得到的协方差改进估计

$$\boldsymbol{\beta}^*(\sigma^2) = \hat{\boldsymbol{\beta}} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}' \left(\frac{\mathbf{W}}{\sigma^2} + \mathbf{H}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{H}' \right)^{-1} (\mathbf{H}\hat{\boldsymbol{\beta}} - \mathbf{u}),$$

等价于

$$\boldsymbol{\beta}^*(\sigma^2) = \left(\frac{\mathbf{X}'\mathbf{X}}{\sigma^2} + \mathbf{H}\mathbf{W}^{-1}\mathbf{H}' \right)^{-1} \left(\frac{\mathbf{X}'\mathbf{y}}{\sigma^2} + \mathbf{H}\mathbf{W}^{-1}\mathbf{u} \right).$$

这就是通常的混合估计.

- 学习重点：最小二乘估计及其性质
- 需要掌握分块估计、约束估计、广义最小二乘估计、协方差改进估计的思想
- 了解最小二乘估计稳健性相关理论